

# Support Vector Machines Solver

Jules Pondard - Joseph de Vilmares

3 janvier 2017

## Introduction

On cherche à apprendre un classifieur de points dans  $\mathbb{R}^n$  en deux catégories. On dispose pour cela d'un ensemble d'entraînement : des points  $x_i \in \mathbb{R}^n$  et leur classe  $y_i \in \{-1, 1\}$ . Un SVM essaie de trouver l'hyperplan séparateur entre les deux catégories optimal, en un certain sens à définir.

Formellement, un SVM minimise  $\frac{1}{2}\|w\|_2^2 + C1^T z$  sous les contraintes  $z \geq 0$  et  $y_i(w^T x_i) \geq 1 - z_i$  pour  $1 \leq i \leq m$ , en  $w \in \mathbb{R}^n$  et  $z \in \mathbb{R}^m$ .

Durant tout ce rapport on s'intéressera à un exemple : deux nuages de points de  $\mathbb{R}^2$  obtenus comme des gaussiennes de covariance  $I_2$  et d'espérances respectives  $\begin{pmatrix} 0 \\ 0 \end{pmatrix}$  et  $\begin{pmatrix} 2 \\ 0 \end{pmatrix}$ .

## 1 Méthode barrière

On applique tout d'abord la méthode barrière, en utilisant une méthode de Newton à chaque pas : on minimise  $f(w, x) = t(\frac{w^T w}{2} + C1^T z) - \sum_{i=1}^m \log(z_i) - \sum_{i=1}^m \log(y_i(w^T x_i) - 1 + z_i)$  avec un pas  $t$  qui tend vers l'infini. On a pris  $t = 1$  au début et on multiplie  $t$  par 10 à chaque étape.

Pour appliquer la méthode de Newton, on calcule  $\nabla f$  avec



- $\frac{\partial f}{\partial w_i} = tw_i - \sum_{k=1}^m \frac{y_k x_k^i}{y_k(w^T x_k) - 1 + z_k}$
- $\frac{\partial f}{\partial z_i} = tC - \frac{1}{z_i} - \frac{1}{y_i(w^T x_i) - 1 + z_i}$

Pour la hessienne  $\nabla^2 f$ , on utilise



- $\frac{\partial^2 f}{\partial w_i \partial w_j} = t\delta_{i=j} + \sum_{k=1}^m \frac{x_k^i x_k^j}{(y_k(w^T x_k) - 1 + z_k)^2}$
- $\frac{\partial^2 f}{\partial w_i \partial z_j} = \frac{y_j x_j^i}{(y_j(w^T x_j) - 1 + z_j)^2}$
- $\frac{\partial^2 f}{\partial z_i \partial z_j} = \delta_{i=j} \left( \frac{t}{z_i^2} + \frac{1}{(y_i(w^T x_i) - 1 + z_i)^2} \right)$

On fait varier  $C$  et on affiche, par dessus le nuage de points, la droite séparatrice trouvée et la droite "optimale" (médiatrice des espérances des gaussiennes). C'est le graphe de gauche. On affiche de plus le gap à droite.

C=1 :



C=100 :



On se rend compte que plus  $C$  est grand, plus la solution obtenue est proche de la solution optimale : la pénalité  $C1^Tz$  est en effet plus importante. On donne ainsi le pourcentage d'erreur sur un ensemble de test en fonction de  $C$ .

C	1	10	100
Erreur			

## 2 CVX

On n'a pas réussi à utiliser Libsvm qui doit être mieux optimisée pour le problème en question.